

# 电商用户价值分层与精准营销策略-数据分析报告

## 一. 项目背景与目标

### 1.1 项目背景

当前电商行业获客成本持续攀升，粗放式运营已无法支撑平台长期增长，精细化用户运营成为提升平台营收、降低用户流失的核心抓手。多数电商平台面临用户画像模糊、价值分层不清晰、运营策略无差别、资源投入 ROI 低的痛点，无法精准定位高价值用户，也无法针对性解决用户流失问题。

本项目基于电商平台用户全维度行为数据，完成用户全景画像搭建、用户价值分层与行为规律挖掘，为平台精细化运营提供数据支撑与可落地的策略建议。

### 1.2 项目核心目标

- 完成数据清洗与预处理，保障分析数据的准确性与有效性；
- 进行 EDA 探索性数据分析，通过数据分布、相关性、行为洞察等搭建平台用户全景画像，明确核心用户群体的人口属性、地域、兴趣与品类偏好特征；
- 基于 RFM 经典模型进行优化，构建拥有 4 个新的优化指标的新模型 RFM-I，完成更精准用户价值分层，在 8 种用户画像的基础上新增 7 种用户画像；
- 生成用户画像可视化，进行传统 RFM 和优化算法的 ROI 对比测算，直观展示优化算法带来的边际增量，输出分群体、可落地、可验证的精细化运营策略，助力平台提升用户留存、复购与整体营收。

### 1.3 数据说明

数据来源：公开电商平台用户行为与属性数据集。

数据规模：1000 条用户样本，16 个特征字段，覆盖用户属性、行为特征、消费价值三大维度。

核心字段分类：

| 字段分类 | 核心字段                         |
|------|------------------------------|
| 用户属性 | 用户 ID、性别、年龄、地域、兴趣标签          |
| 行为特征 | 上次登录距今天数、网站停留时长、浏览页面数、是否订阅邮件 |
| 消费特征 | 购买频率、平均订单价值、总消费额、产品品类偏好      |

## 二、分析流程与数据预处理

### 2.1 整体分析流程

本项目严格遵循数据分析全流程规范，执行逻辑为：

数据预处理→用户全景画像 EDA→用户行为深度分析→RFM-I 用户价值分层→消费行为影响因素分析→业务策略输出

### 2.2 数据预处理

为避免“垃圾进、垃圾出”，保障分析结论的严谨性，执行以下预处理操作：

数据清洗：剔除完全重复的用户数据、消费额为负的逻辑错误数据；非核心字段缺失值采用众数填充，避免样本量损失。

异常值处理：基于电商业务逻辑，保留 18-70 岁的核心运营用户，剔除无民事行为能力、行为特征与主流群体差异极大的离群样本，避免干扰分析结论。

特征工程：基于原始字段，构建 RFM 三大核心指标和三个优化指标（R：最近一次登录距今天数、F：购买频率、M：总消费额、T：意向深度、L：活跃连接度、D：购买力背景），

为后续用户价值分群做数据准备。

可视化代码优化：针对用户上次登录距今天数分布可视化的代码报错问题，放弃原有封装函数，采用【手绘绘制直方图+KDE 曲线缩放匹配】的方案，既保留了分布特征与平滑趋势，又完美匹配直方图的用户数量刻度，最终实现了合规、准确的可视化效果。

核心代码如下：

```
# 环境准备与库导入
import os
import pandas as pd
import numpy as np
import matplotlib.pyplot as plt
import seaborn as sns
import warnings
warnings.filterwarnings('ignore')
# 设置中文字体
plt.rcParams['font.sans-serif'] = ['SimHei']
plt.rcParams['axes.unicode_minus'] = False

# 根据实际修改文件路径
input_path = r'C:/Users/DYX/DSFX/user_personalized_features.csv'
output_dir = r'C:/Users/DYX/DSFX/rfm_analysis'
os.makedirs(output_dir, exist_ok=True)

# 数据加载与预处理函数
def load_and_preprocess(filepath):
    """数据加载与预处理"""
    df = pd.read_csv(filepath)

    # 数据质量检查
    print("=" * 60)
    print("第一阶段：数据质量检查")
    print("=" * 60)
    print(f"数据规模: {df.shape[0]} 行 x {df.shape[1]} 列")
    print(f"缺失值: {df.isnull().sum().sum()}")

    # 异常值检查
    age_outliers = df[(df['Age'] < 18) | (df['Age'] > 70)].shape[0]
    freq_outliers = df[df['Purchase_Frequency'] < 0].shape[0]
    spending_outliers = df[df['Total_Spending'] < 0].shape[0]

    print(f"年龄异常值: {age_outliers}")
    print(f"购买频率异常值: {freq_outliers}")
```

```

print(f"消费额异常值: {spending_outliers}")

# 记录清洗前数据量
before_rows = df.shape[0]
# 数据预处理: 过滤异常数据
df = df[(df['Age'] >= 18) & (df['Age'] <= 70)]
df = df[df['Purchase_Frequency'] >= 0]
df = df[df['Total_Spending'] >= 0]

# 记录清洗后数据量
after_rows = df.shape[0]

print(f"清洗前数据量: {before_rows}")
print(f"清洗后数据量: {after_rows}")
print(f"删除异常数据: {before_rows - after_rows} 行")

return df

# 执行数据加载
df = load_and_preprocess(input_path)
df.head()

```

## 第一阶段：数据质量检查

数据规模：1000 行 x 15 列

缺失值：0

年龄异常值：0

购买频率异常值：0

消费额异常值：0

清洗前数据量：1000

清洗后数据量：1000

删除异常数据：0 行

|      | User_ID | Age | Gender | Location | Income | Interests  | Last_Login | Purchase_F | Average_O | Total_Spe | Product_C  | Time_Spent | Pages_Vis | Newsletter |
|------|---------|-----|--------|----------|--------|------------|------------|------------|-----------|-----------|------------|------------|-----------|------------|
| 0 #1 |         | 56  | Male   | Suburban | 38037  | Sports     | 5          | 7          | 18        | 2546      | Books      | 584        | 38        | TRUE       |
| 1 #2 |         | 46  | Female | Rural    | 103986 | Technology | 15         | 7          | 118       | 320       | Electronic | 432        | 40        | FALSE      |
| 2 #3 |         | 32  | Female | Suburban | 101942 | Sports     | 28         | 1          | 146       | 3766      | Apparel    | 306        | 1         | TRUE       |
| 3 #4 |         | 60  | Female | Suburban | 71612  | Fashion    | 18         | 3          | 163       | 4377      | Apparel    | 527        | 29        | FALSE      |

### # 1. 性别分布

```

plt.figure(figsize=(8, 5))
gender_count = df['Gender'].value_counts()
sns.barplot(x=gender_count.index, y=gender_count.values, palette='Blues_d')

```

```
plt.title('平台用户性别分布', fontsize=14)
plt.xlabel('性别', fontsize=12)
plt.ylabel('用户数量', fontsize=12)
# 给柱子加数值标签
for i, v in enumerate(gender_count.values):
    plt.text(i, v+5, str(v), ha='center', fontsize=10)
plt.savefig('用户性别分布.png', dpi=300, bbox_inches='tight')
plt.show()
```

## # 2. 年龄分层分布

```
df['Age_Group'] = pd.cut(df['Age'], bins=[18, 25, 35, 45, 55, 70], labels=['18-25 岁', '26-35 岁', '36-45 岁', '46-55 岁', '56 岁以上'])
plt.figure(figsize=(10, 5))
age_count = df['Age_Group'].value_counts().sort_index()
sns.barplot(x=age_count.index, y=age_count.values, palette='Purples_d')
plt.title('平台用户年龄分层分布', fontsize=14)
plt.xlabel('年龄分组', fontsize=12)
plt.ylabel('用户数量', fontsize=12)
for i, v in enumerate(age_count.values):
    plt.text(i, v+5, str(v), ha='center', fontsize=10)
plt.savefig('用户年龄分布.png', dpi=300, bbox_inches='tight')
plt.show()
```

## # 3. 用户地域分布

```
plt.figure(figsize=(8, 5))
location_count = df['Location'].value_counts()
sns.barplot(x=location_count.index, y=location_count.values, palette='Greens_d')
plt.title('平台用户地域分布', fontsize=14)
plt.xlabel('居住地', fontsize=12)
plt.ylabel('用户数量', fontsize=12)
for i, v in enumerate(location_count.values):
    plt.text(i, v+5, str(v), ha='center', fontsize=10)
plt.savefig('用户地域分布.png', dpi=300, bbox_inches='tight')
plt.show()
```

## # 4. 用户兴趣分布

```
plt.figure(figsize=(12, 6))
interest_count = df['Interests'].value_counts()
sns.barplot(x=interest_count.values, y=interest_count.index, palette='Oranges_d')
plt.title('平台用户兴趣分布', fontsize=14)
```

```
plt.xlabel('用户数量', fontsize=12)
plt.ylabel('兴趣标签', fontsize=12)
plt.savefig('用户兴趣分布.png', dpi=300, bbox_inches='tight')
plt.show()
```


### 三、核心分析过程与业务洞察

#### 3.1 平台用户全景画像分析


通过多维度交叉分析,明确平台核心用户的群体特征,为精细化运营提供基础用户地图。

##### 3.1.1 用户人口属性分布

性别分布:平台男性用户 526 人,占比 52.7%;女性用户 474 人,占比 47.3%,男女用户结构均衡,无明显性别倾斜。运营策略需兼顾两性需求,同时可针对占比略高的男性用户,适度倾斜对应品类的运营资源。




年龄分层分布:平台核心用户集中在 36-55 岁,其中 36-45 岁用户 231 人、46-55 岁用户 223 人,合计占比超 45%,是平台的营收主力群体;18-25 岁年轻用户仅 152 人,占比最低,是平台用户增长的核心潜力缺口。



##### 3.1.2 用户地域与偏好分布

地域分布：郊区用户 349 人，占比最高；城市用户 344 人，农村用户 307 人。下沉市场（郊区+农村）用户合计占比超 65%，是平台的用户基本盘，运营需重点匹配下沉市场用户的消费习惯。




兴趣与品类偏好：

用户兴趣 TOP3：Sports（运动）、Fashion（时尚）、Food（美食）；

产品品类偏好 TOP3：Apparel（服饰）、Electronics（数码产品）、Books（图书）；

核心关联洞察：用户兴趣与品类偏好高度匹配，运动、时尚兴趣直接对应服饰品类的核心消费，为场景化推荐、品类联动运营提供了数据支撑。



## 3.2 用户行为深度分析

### 3.2.1 构建优化指标

基础的 RFM 指标已在数据中，在已有数据的基础上构建意向度 I-Score、转化摩擦系数、活跃连接度和购买力背景 4 个优化指标。

意向度指标：对用户的浏览时长和浏览页数进行归一化处理并加权求和，通过这个指标能够识别出有意愿购买但没有行动的用户。如果用户的浏览时间长，浏览页数多，即使没有下单，也说明这类用户对产品购买意向度较高或对页面内容感兴趣，而这类用户往往是营销投入回报率最高的群体，针对这类群体，可以尝试发放优惠券或推荐商品来完成转化。

$$\text{意向度} = 0.5 * \text{浏览时长} + 0.5 * \text{浏览页数}$$

转化摩擦系数衡量用户纠结程度，如果系数高，说明用户犹豫很久才下单或没有下单，这类用户往往是有选择困难症或是在货比三家，转化摩擦系数将高购买意向但没有转化的用

户进行细分。

$$\text{摩擦系数} = \text{浏览页数} / (\text{购买次数} + 1)$$

活跃连接度指标重新定义了用户的忠诚程度，高说明用户订阅了且最近 7 天登录，中说明用户未订阅但最近 7 天登录，低说明用户订阅了但最近 7 天甚至 30 天都未登录，这个指标强调的是用户行为的活跃度。

购买力背景指标是基于用户收入进行角色分层，但不计入综合得分，而是作为分层后的修正标签，例如当用户消费金额相同时，我们可以向高收入低消费的用户推荐更高价值的商品，对于低收入高消费的用户需要定制维护方案，避免用户流失，这个指标对于定制差异化运营方案有重要意义。

```
# I (Intent - 意向深度)
def min_max_normalize(series, reverse=False):
    min_val, max_val = series.min(), series.max()
    if max_val == min_val:
        return pd.Series([50] * len(series))
    if reverse:
        return ((max_val - series) / (max_val - min_val)) * 100
    return ((series - min_val) / (max_val - min_val)) * 100
df['Time_Spent_Norm'] = min_max_normalize(df['Time_Spent_on_Site_Minutes'])
df['Pages_Viewed_Norm'] = min_max_normalize(df['Pages_Viewed'])
df['I_Score'] = 0.5 * df['Time_Spent_Norm'] + 0.5 * df['Pages_Viewed_Norm']
df['Friction'] = df['Pages_Viewed'] / (df['Purchase_Frequency'] + 1)
```

```
# L (Loyalty - 活跃连接度)
def calculate_loyalty(row):
    subscribed = row['Newsletter_Subscription']
    login_days = row['Last_Login_Days_Ago']
    if subscribed and login_days < 7:
        return 3
    elif not subscribed and login_days < 7:
        return 2
    else:
        return 1
df['L_Score'] = df.apply(calculate_loyalty, axis=1)
```

```
# D (Demographics - 购买力背景)
income_33 = df['Income'].quantile(0.33)
income_66 = df['Income'].quantile(0.66)
def income_level(income):
    if income <= income_33:
        return 'Low'
    elif income <= income_66:
```

```

        return 'Medium'
    else:
        return 'High'
df['Income_Level'] = df['Income'].apply(income_level)

```

## 第二阶段：特征工程 - 构建优化指标

I\_Score 范围：[0.00, 98.83]

Friction 范围：[0.10, 49.00]

L\_Score 分布：{1: 824, 3: 99, 2: 77}


Income\_Level 分布：{'High': 340, 'Low': 330, 'Medium': 330}

Interest\_Match 匹配率：0.0%

### 3.2.2 EDA 探索性数据分析

EDA 分析包括关键分布分析和关键相关性分析。关键分布分析包括 4 类：总消费金额和消费次数的直方图，用户收入和总消费金额的散点图，是否订阅和最近一次登陆的箱线图，意向度和消费次数的直方图。

关键分布分析中，从箱线图可以看出订阅的用户总体活跃度要比未订阅用户高，从意向度分布图来看，意向度在 40-60 时消费次数较高。关键相关性分析可看出用户的浏览时间和浏览页面数与购买次数之间存在相关性，高摩擦用户的浏览页面次数 30+ 时才可能购买一次，高收入低消费人群在高收入人群中占比达 54.1%，后续针对这两类用户需要制定精准的商品推荐或优惠券发放等策略。





=====

第三阶段：EDA探索性数据分析

=====

关键相关性分析：

Time\_Spent vs Purchase\_Frequency 相关系数：-0.028


Pages\_Viewed vs Purchase\_Frequency 相关系数：0.026

高摩擦用户(前25%)特征：

- 平均浏览页数：34.3
- 平均购买频率：1.6
- 平均消费金额：2514

高收入低消费群体：

- 用户数：184
- 占高收入群体比例：54.1%



### 3.3 RFM-I 用户价值分层分析

基于改进的电商行业经典的 RFM 模型，设计 RFM-I 模型，完成用户价值分群，解决平

台用户价值不清晰、运营资源错配的核心痛点。

当前用户结构以一般用户为主体，高价值用户占比较低，但存在一定的高潜力与可挽留用户，后续运营应重点围绕“核心VIP/重要价值用户留存”“高潜流失客挽回”“低价值用户成本控制”三类策略展开。

从用户价值分层结果来看，一般用户数量最多，共443人，占比44.3%，说明当前用户群体中中等价值用户占据主体，其平均消费、购买频率和意向分均处于中间水平，是平台稳定运营的基础人群。高价值用户中，核心VIP虽然仅23人，占比2.3%，但平均消费、购买频率、意向分和综合分均较高，是最具价值的核心客户；重要价值用户、重要保持用户也表现出较高的消费能力和购买活跃度，应作为重点维护对象，通过会员权益、专属优惠、个性化推荐等方式提升忠诚度。与此同时，重要挽留用户和高潜流失客虽然消费金额较高，但购买频率或意向分偏低，说明这部分用户具有较高商业价值但存在流失风险，应及时进行召回和促活。低价值用户、羊毛党/低值用户等群体综合价值较低，消费贡献有限，应避免过度投入营销资源。

整体来看，用户分层结果能够较好地地区分不同用户的消费能力、活跃程度和潜在价值，能够为后续精细化运营和差异化营销提供可靠依据。

关键代码：

```
# 基础 RFM 分层逻辑
if r > 60 and f > 60 and m > 60:
    base_label = "重要价值用户"
elif r > 60 and m > 60 and f < 40:
    base_label = "重要发展用户"
elif r < 40 and f > 60 and m > 60:
    base_label = "重要保持用户"
elif r < 40 and m > 60:
    base_label = "重要挽留用户"
elif r > 60 and f > 40 and m < 40:
    base_label = "一般发展用户"
elif r > 60 and f < 40 and m < 40:
    base_label = "一般维持用户"
elif r < 40 and f < 40 and m < 40:
    base_label = "低价值用户"
else:
    base_label = "一般用户"

# 关键修正逻辑
if base_label in ["低价值用户", "一般维持用户"] and income == "High" and i > 60:
    return "高潜沉睡用户"
if income == "High" and i > 70 and f < 40 and m < 50:
    return "纠结土豪"
if base_label in ["一般维持用户", "一般发展用户"] and i > 80 and friction > df['Friction'].quantile(0.6):
    return "犹豫型潜力用户"
if income == "Low" and i > 70 and f < 40:
```

```


return "隐形活跃者"
if income == "High" and r < 40 and m > 50:
    return "高潜流失客"
if m > 70 and f > 70 and i > 60:
    return "核心 VIP"
if income == "Low" and i < 40 and m < 40:
    return "羊毛党/低值"


return base_label

```

用户分层统计：

|              | 用户数 | 平均消费    | 平均购买频率 | 平均意向分 | 平均收入      | 平均综合分 | 占比(%) |
|--------------|-----|---------|--------|-------|-----------|-------|-------|
| User_Segment |     |         |        |       |           |       |       |
| 一般用户         | 443 | 2368.12 | 5.17   | 48.80 | 84305.72  | 54.31 | 44.3  |
| 一般发展用户       | 81  | 1117.95 | 6.43   | 49.84 | 87107.43  | 52.67 | 8.1   |
| 重要挽留用户       | 67  | 4134.42 | 2.57   | 46.53 | 59698.61  | 58.59 | 6.7   |
| 高潜流失客        | 64  | 3990.70 | 4.92   | 44.09 | 121985.09 | 65.40 | 6.4   |
| 低价值用户        | 50  | 1036.52 | 1.68   | 42.79 | 94734.76  | 20.87 | 5.0   |
| 重要发展用户       | 48  | 3873.96 | 1.62   | 48.91 | 81230.60  | 65.41 | 4.8   |
| 一般维持用户       | 47  | 1055.40 | 1.47   | 45.83 | 91335.23  | 33.57 | 4.7   |
| 重要价值用户       | 47  | 3960.19 | 7.47   | 42.28 | 73500.94  | 86.82 | 4.7   |
| 重要保持用户       | 39  | 4030.23 | 7.49   | 48.00 | 57995.92  | 75.26 | 3.9   |
| 隐形活跃者        | 34  | 2756.79 | 1.32   | 77.99 | 36273.32  | 47.28 | 3.4   |
| 羊毛党/低值       | 32  | 1019.56 | 5.50   | 23.08 | 37896.19  | 37.05 | 3.2   |
| 核心VIP        | 23  | 4171.39 | 8.17   | 71.09 | 59382.39  | 88.86 | 2.3   |
| 高潜沉睡用户       | 12  | 1318.17 | 1.75   | 74.34 | 121952.83 | 35.20 | 1.2   |
| 犹豫型潜力用户      | 7   | 738.86  | 2.43   | 90.23 | 60211.71  | 34.69 | 0.7   |
| 纠结土豪         | 6   | 1156.67 | 1.67   | 78.86 | 125519.00 | 30.24 | 0.6   |






### 3.4 ROI 测算

在相同预算约束下，优化 RFI 策略的边际 ROI 明显优于传统 RFM 策略，说明引入用户意向特征后，能够更精准地识别高转化潜力用户，提升营销资源使用效率。

从测算结果来看，传统 RFM 策略主要面向 RFM 得分前 20% 的用户，共覆盖 200 人，优惠券成本为 2000 元，带来边际收益 2081 元，边际 ROI 为 4.0%，整体收益略高于成本，说明传统高价值用户筛选方式具备一定效果，但增量收益有限。相比之下，优化 RFI 策略将投放对象进一步细分为核心用户和潜力用户，共覆盖 159 人，实际成本为 1590 元，仅使用总预算的 15.9%，但边际收益达到 2123 元，边际 ROI 提升至 33.5%。这表明 RFI 策略虽然覆盖人数更少，但目标用户质量更高，尤其是新挖掘的潜力用户具有更高的转化提升空间，能够以更低成本获得更高的单位投入回报。整体来看，优化 RFI 策略在精准营销场景下更具应用价值，后续可优先用于优惠券投放、用户召回和潜力客户激活等运营活动。



=====

## 第六阶段：ROI测算

=====

### 【假设参数】

总预算：10000元  
优惠券成本：10元/人  
平均客单价：104元

### 【转化率假设】

RFM前20%用户：自然转化率 20.0%，发券后 30.0%，边际提升 10.0%  
核心用户：自然转化率 25.0%，发券后 30.0%，边际提升 5.0%  
潜力用户：自然转化率 1.0%，发券后 20.0%，边际提升 19.0%

### 【方案A - 传统RFM策略】

目标用户数：200  
成本：2000元  
边际收益（增量）：2081元  
边际ROI：4.0%

### 【方案B - 优化RFI策略】

核心用户：70  
新挖掘潜力用户：89  
总目标用户数：159  
实际成本：1590元（预算使用率：15.9%）  
边际收益（增量）：2123元  
边际ROI：33.5%

## 3.5 用户消费行为影响因素分析

在本项目在传统 RFM 用户价值分析框架基础上，进一步引入 I-Score（意向深度）、Friction（转化摩擦系数）、L-Score（活跃连接度）和 Income\_Level（购买力背景）等优化指标，构建更适用于电商精细化运营场景的 RFM-I 用户价值分析体系。相比仅依赖消费金额、购买频率和最近活跃时间的传统模型，优化后的模型能够同时识别“已经产生高消费的用户”和“尚未充分转化但具备消费潜力的用户”，从而更全面地解释用户消费行为差异。

从消费价值影响因素来看，消费金额和购买频率仍然是判断用户当前价值的基础指标。高消费、高频购买用户通常对应核心VIP、重要价值用户、重要保持用户等高价值群体，是平台当前 GMV 的主要贡献来源，应通过会员权益、专属优惠、个性化推荐等方式重点维护。但仅依靠传统 RFM 指标容易忽略部分“高意向、低转化”用户，导致运营资源过度集中在已有高价值用户上，限制潜在增量空间。

意向深度是挖掘潜在消费用户的重要补充指标。浏览时长较长、浏览页面数较多的用户，即使当前购买频率或消费金额不高，也可能已经表现出较强的购买兴趣。此类用户往往处于

转化前阶段，适合通过优惠券、商品推荐、限时活动等方式推动下单。因此，I-Score 的加入能够帮助平台识别犹豫型潜力用户、高潜沉睡用户、隐形活跃者等传统 RFM 难以发现的潜在增长人群。

转化摩擦系数能够反映用户从浏览到购买之间的阻碍程度。高摩擦用户通常表现为浏览页面较多但购买次数较少，说明其可能存在比价、犹豫、决策成本高等问题。这类用户并非完全低价值用户，而是需要通过降低决策门槛来促进转化，例如强化商品评价、优化推荐排序、提供价格激励或简化购买路径。

活跃连接度能够补充传统 RFM 对用户状态的判断。订阅邮件且近期登录的用户，说明其与平台仍保持较强连接，具备持续触达和复购培养价值；而长期未登录但历史消费较高的用户，则可能存在流失风险，需要及时召回。该指标有助于区分“真实低价值用户”和“暂时沉睡但仍可激活用户”。

从购买力背景来看，收入水平不应单独作为用户价值判断标准，而应作为运营策略修正变量。高收入低消费用户可能存在消费潜力未释放的问题，适合推荐更高价值商品或组合套餐；低收入高消费用户则需要重点维护消费体验，避免因价格敏感或服务体验下降导致流失。因此，购买力背景指标能够帮助平台制定更细分的商品推荐和用户维护策略。

综合来看，影响用户消费行为的因素并非单一的消费金额，而是由消费能力、购买频率、活跃状态、购买意向、转化阻力和购买力背景共同决定。传统 RFM 模型更适合识别当前高价值用户，而优化后的 RFM-I 模型能够进一步发现潜力用户、流失风险用户和高意向低转化用户。结合后续 ROI 测算结果，优化 RFI 策略在覆盖人数更少、成本更低的情况下取得更高边际 ROI，说明新增指标能够有效提升用户识别精度和营销资源利用效率。后续平台应围绕“维护核心高价值用户、激活高意向潜力用户、召回高价值流失用户、控制低价值用户投入”四个方向开展精细化运营。